ESIEE
PARIS

Badr TAJINI

Lecturer-Researcher
-
Co-founder & CTO

About me

- Co-founder & CTO - Researcher in Robotics & AI
- Member of the Parietal team - GdR CNRS 2286 – Mathematical Imaging and its Applications (MIA)
- Research interests :
  - Agentic AI & Robotics (VLAs)
  - Computer Vision (VLMs),
  - Natural Language Processing (LLMs),
  - Brain NeuroImaging and Neurosciences.
- Last Job : ML Research & Systems, EDF
- Currently :
  - Lecturer-Researcher at ESIEE engineering school
  - Co-founder & CTO - SF Bay Area (Stealth Starup)

Assistant pédagogique RL/GRPO

Plan de tutorat intelligent sur 7 semaines

Étudiants en ingénierie IA avancée : construire un assistant intelligent pour le raisonnenent en Python

1 Question étudiant

```python
def somme_pairs(n):
    s = 0
    for i in range(n):
        if i % 2 == 0:
            s += i
    return s
```

- Question ou problème en Python
- Contexte et contraintes
- Objectif de compréhension ou d'amélioration

2 Assistant raisonneur

- Comprendre
- Raisonner
- Proposer

Expliquer • Déduire • Vérifier

3 Sortie structurée

```
{
 "reformulation" : "Explication claire
  du problème posé par l'étudiant",
 "raisonnement" : "Étapes logiques et
  hypothèses utilisées",
 "exemple" : "Code Python illustrant
  la solution ou l'idée clé",
 "vérification" : "Tests, cas limites et
  validation du résultat",
 "conclusion" : "Synthèse et conseils
  pour progresser"
}
```

4 Dashboard / prototype

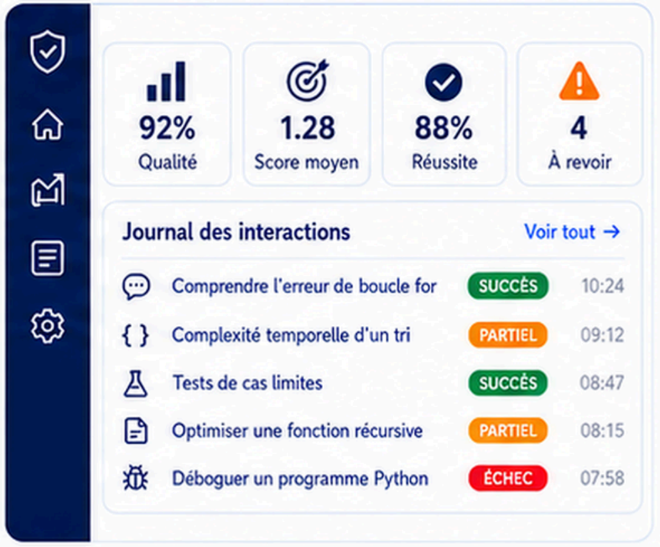

1 domaine étroit

45 questions sélectionnées

3 stratégies d'entraînement

5 signals (rewards)

7 semaines de tutorat

Baseline → SFT léger → GRPO contrôlé → soutenance

1. Cadrage du projet

Un assistant mesurable, pas un chatbot généraliste

Définir le périmètre d'un assistant académique sur un domaine restreint et mesurable

1 Entrée

Question d'un étudiant (Python)

```
Écrire une fonction
qui retourne la
factorielle d'un
nombre n.

Exemple : n = 5 → 120
```

2 Domaine cible

Python débutant + algorithmique

- Syntaxe de base Python
- Structures de contrôle, boucles, fonctions simples, listes, variables

3 Réponse attendue

1. Reformulation
L'assistant reformule la question pour vérifier la compréhension.

2. Raisonnement public
Il explique la démarche pas à pas, de manière agogique.

3. Exemple
Il fournit un exemple de code fonctionnel et commenté.

4. Vérification
Il vérifie le résultat avec un ou plusieurs tests simples.

4 Preuve

Logs + Score

- Horodatage
- Entrée utilisateur
- Sortie structurée
- Tests exécutés
- Score qualité

Score : 0.87 / 1.00

Contraintes non négociables

- **Domaine étroit** — Python débutant + algorithmique
- **Sortie structurée obligatoire** — 4 parties attendues
- **30 à 50 questions ciblées** — corpus synthétique
- **Comparaison A / B / C** — métriques identiques
- **GRPO en bonus** — optimisation possible ultérieurement

0 scope généraliste

100% sorties loguées

≥95% format valide

GO : périmètre gelé

GO : cadrage validé

Un périmètre clair aujourd'hui, des résultats fiables demain.

2. Modèles et outils

Choisir simple, mesurable et rejouable

élevée

Valeur pédagogique

faible

promptfoo

campagnes d'évaluation

tests automatisés, scoring, rapports

PyRIT

sondes de robustesse

agents red team, scénarios multi-étapes

API LLM — baseline rapide

voie rapide

prompts simples, réponses, métriques

Gemma 4 + Unsloth — voie fine-tuning

fine-tuning (SFT/LoRA)

adaptation domaine, instruction tuning

faible → Effort d'intégration → élevé

Repères techniques

- **Structured outputs** — réponses JSON fiables
- **Pydantic / JSON** — validation stricte
- **SQLite logs** — logs compacts, traçables
- **GRPOTrainer** — optimisation RL efficace
- **Fonctions de récompense** — contrôle du comportement

Recommandations pour un projet étudiant

1. **1 baseline par prompting** — démarrer simple, obtenir une première vérité terrain
2. **SFT/LoRA si gain mesuré** — fine-tuning ciblé uniquement si amélioration significative
3. **GRPO seulement après benchmark** — après avoir établi une baseline solide

4 briques

1 notebook central

2 versions comparées

100% tests versionnés

3. Corpus et benchmark

Choisir peu, mais choisir juste

Un jeu de données synthétique pour tester sans danger

1 Questions Python

fonctions, boucles, types

socle

2 Questions algorithmiques

recherche, tri, complexité

raisonnement

3 Questions pièges

off-by-one, None, mutabilité

robustesse

4 Questions IA

limites, vérification, hallucination

prudence

15 smoke tests → **30** cas développement → **15** cas test final

Split strict :
les 15 cas finaux ne servent jamais au tuning

45 questions

8 catégories

30 dev

15 test

100% cas scorés

Pas de benchmark, pas de conclusion

4. Architecture cible

Transformer un modèle en système traçable

1 Question

- Question utilisateur
- Contexte métier
- Métadonnées

2 Prompt versionné

v1.3.2

- Prompts stockés et versionnés
- Traçabilité 100%
- Rollback possible

3 Modèle

- LLM (ex. GPT-4o)
- Température, top_p
- Contexte & outils

4 Validateur JSON

- Schéma JSON strict
- Validation syntaxe
- Champs obligatoires
- Types & formats

5 Garde-fous

- Refus si secret
- Incertain si doute
- Validation du format
- Seuils de qualité

6 Interface web

- Consultation
- Visualisation
- Export & partage
- Permissions

7 SQLite / logs

- Stockage local
- Logs horodatés
- Requêtes traçables
- Audit & rétention

Mode candidat :
baseline, structuré, few-shot, SFT, GRPO

Exemple de réponse (JSON)

```
{
  "question_id": "Q-2025-0012",
  "strategy": "baseline",
  "answer_blocks": [ { "type": "markdown", "content": "..." } ],
  "valid_schema": true,
  "score": 0.92,
  "latency_ms": 6243
}
```

Observabilité & traçabilité

- Corrélation de bout en bout
- Rejouabilité (prompt + modèle)
- Indicateurs qualité & dérives
- Reproductibilité des résultats

1	≥95%	100%	P95 < 8s
API /answer	JSON valide	sorties journalisées	latence cible

Baseline d'abord, optimisation ensuite

5. Voie rapide SFT avec Gemma 4

Unsloth : aller vite sans perdre le contrôle

P0 Prompting

baseline
sans
entraînement

P1 LoRA / QLoRA

- Gemma 4 E2B/E4B (basis modèles)
- dataset conversationnel
- Unsloth : rapide et efficace

P2 Validation

- même benchmark
- logs détaillés
- analyse des erreurs
- métriques comparables

P3 Export

- GGUF
- démo locale si utile
- documentation et guides

À retenir :
LoRA avant full fine-tuning

FFT ≈ 4×
plus de VRAM

préserver le raisonnement :
exemples de raisonnement

modèles plus grands :
26B-A4B / 31B
si A100

Guide GPU : choisir la bonne voie

GPU modeste
→ prompting

GPU moyen
→ LoRA E2B/E4B

GPU fort
→ modèles plus grands

1
baseline d'abord

30
dev

15
test

1
décision GO/NO-GO

Objectif : solution rapide, pas course au plus grand modèle

5. Voie rapide SFT avec Gemma 4

Unsloth : aller vite sans perdre le contrôle

P0 Prompting

baseline
sans
entraînement

P1 LoRA / QLoRA

- Gemma 4 E2B/E4B (basis modèles)
- dataset conversationnel
- Unsloth : rapide et efficace

P2 Validation

- même benchmark
- logs détaillés
- analyse des erreurs
- métriques comparables

P3 Export

- GGUF
- démo locale si utile
- documentation et guides

À retenir :
LoRA avant full fine-tuning

FFT ≈ 4×
plus de VRAM

préserver le raisonnement :
exemples de raisonnement

modèles plus grands :
26B-A4B / 31B
si A100

Guide GPU : choisir la bonne voie

GPU modeste
→ prompting

GPU moyen
→ LoRA E2B/E4B

GPU fort
→ modèles plus grands

1
baseline d'abord

30
dev

15
test

1
décision GO/NO-GO

Objectif : solution rapide, pas course au plus grand modèle

5. Voie rapide SFT avec Gemma 4

Unsloth : aller vite sans perdre le contrôle

P0 Prompting

baseline
sans
entraînement

P1 LoRA / QLoRA

- Gemma 4 E2B/E4B (basis modèles)
- dataset conversationnel
- Unsloth : rapide et efficace

P2 Validation

- même benchmark
- logs détaillés
- analyse des erreurs
- métriques comparables

P3 Export

- GGUF
- démo locale si utile
- documentation et guides

À retenir :
LoRA avant full fine-tuning

FFT ≈ 4×
plus de VRAM

préserver le raisonnement :
exemples de raisonnement

modèles plus grands :
26B-A4B / 31B
si A100

Guide GPU : choisir la bonne voie

GPU modeste
→ prompting

GPU moyen
→ LoRA E2B/E4B

GPU fort
→ modèles plus grands

1
baseline d'abord

30
dev

15
test

1
décision GO/NO-GO

Objectif : solution rapide, pas course au plus grand modèle

5. Voie rapide SFT avec Gemma 4

Unsloth : aller vite sans perdre le contrôle

P0 Prompting

baseline
sans
entraînement

P1 LoRA / QLoRA

- Gemma 4 E2B/E4B (basis modèles)
- dataset conversationnel
- Unsloth : rapide et efficace

P2 Validation

- même benchmark
- logs détaillés
- analyse des erreurs
- métriques comparables

P3 Export

- GGUF
- démo locale si utile
- documentation et guides

À retenir :
LoRA avant full fine-tuning

FFT ≈ 4×
plus de VRAM

préserver le raisonnement :
exemples de raisonnement

modèles plus grands :
26B-A4B / 31B
si A100

Guide GPU : choisir la bonne voie

GPU modeste
→ prompting

GPU moyen
→ LoRA E2B/E4B

GPU fort
→ modèles plus grands

1
baseline d'abord

30
dev

15
test

1
décision GO/NO-GO

Objectif : solution rapide, pas course au plus grand modèle

6. Contrat de sortie et prompting

La qualité commence par une réponse disciplinée

Prompt baseline

Une instruction
sans format imposé,
qualité variable.

Contrat de sortie (réponse JSON)

```
{
  "reformulation": "string",
   Reformulation concise de la demande.
  "reasoning_steps": ["string"],
   Raisonnement par étapes, clair et traçable.
  "example": "string",
   Exemple minimal pertinent.
  "verification": "string",
   Vérification concrète à réaliser.
  "limitations": "string"
   Limites, hypothèses ou incertitudes.
}
```

Prompt amélioré

- Structure imposée
- Exemple minimal
- Vérification concrète
- Incertain si ambigu

Critère	Baseline	Amélioré
JSON valide	~70%	≥95%
Vérification	~35%	≥85%
Réponses trop longues	~30%	<10%
Hallucination	~8%	<2%

3 prompts à comparer

4 blocs obligatoires

0 chaîne cachée

100% vérification attendue

Règle d'or : structure avant style

7. Boucle GRPO contrôlée

Renforcer un comportement mesurable, pas une impression

1 Entrée : prompt

Une question ou instruction

2 Génération
4–8 réponses candidates

- Réponse 1
- Réponse 2
- ...
- Réponse 8

3 Fonctions de récompense
score chaque réponse

Réponse 1	0.85
Réponse 2	0.45
...	
Réponse 8	0.20

4 Mise à jour de la politique
apprendre des signaux de récompense

Modèle amélioré

Répéter jusqu'à convergence

5 Checkpoint évalué
sur benchmark extérieur (tenu de côté)

- Pas de fuite de données
- Mesure objective
- Généralisation réelle

Exemples de fonctions de récompense

- **exactitude** — justesse factuelle
- **format JSON** — structure et validité
- **vérification** — preuves et sources
- **concision** — réponses claires et brèves
- **sécurité** — contenu sûr et conforme

Risque : reward hacking — respecter le format sans être plus juste

5 rewards construites	**4–8** rollouts par prompt	**30** prompts dev (entraîn.)	**15** prompts test final	**0** tuning sur test

GO GRPO seulement si baseline + SFT sont mesurés

8. Mesures et validation

Ce qui n'est pas mesuré n'est pas maîtrisé

1 Score global

2.6 / 3

Objectif
≥ 2.5

2 Exactitude

0.82

Objectif
≥ 0.80

3 JSON valide

97%

Objectif
≥ 95%

4 Vérification

88%

Objectif
≥ 85%

5 Format invalide

3%

Objectif
< 5%

6 Latence P95

6.8 s

Objectif
< 8 s

Matrice d'erreurs — qualité de la réponse (exemple)

	Correct	Problème mineur	Erreur majeure	Invalide (format)	Total
Correct	162	24	6	8	200
Problème mineur	15	48	12	5	80
Erreur majeure	6	14	68	12	100
Invalide (format)	3	2	5	10	20
Total	186	88	91	35	400

Baseline vs GRPO

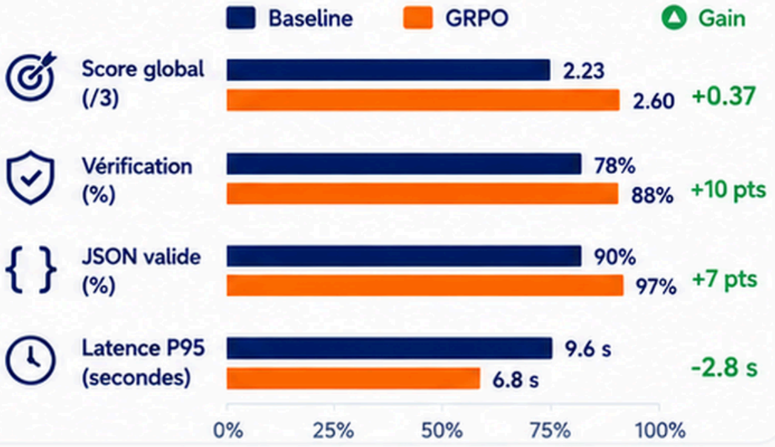

Interprétation

Exactitude domine
Elle garantit des réponses fiables et pertinentes.

JSON garantit intégration
Un format valide et stable évite les ruptures système.

Latence protège expérience utilisateur
Des réponses rapides améliorent l'adoption et la satisfaction.

GO si les gains sont mesurés et les erreurs expliquées

9. Roadmap tutorat sur 7 semaines

Un fil rouge visible, un livrable chaque semaine

Construire une progression défensive et mesurable

S1 — 1
cadrage + repo + 45 questions

Livrable
scope, règles et questionnaire

GO/NO-GO
périmètre

S2 — 2
baseline notebook

Livrable
notebook baseline + logs initiaux

S3 — 3
contrat JSON + prompts

Livrable
contrat JSON + prompts

GO/NO-GO
baseline

S4 — 4
benchmark complet

Livrable
rapport benchmark + résultats

GO/NO-GO
évaluation

S5 — 5
SFT / LoRA si utile

Livrable
modèle entraîné + config

S6 — 6
GRPO + analyse d'erreurs

Livrable
rapport GRPO + erreurs

GO/NO-GO
GRPO

S7 — 7
démo + soutenance

Livrable
slides + démo + rapport final

GO/NO-GO
défense

Équipe & rôles

Données
Collecter, nettoyer et structurer

Prompts
Concevoir les prompts et contrats d'entrées/sorties

Modèle
Choisir, entraîner et adapter (SFT/LoRA, GRPO)

Évaluation
Définir les métriques, tester et analyser

Intégration
Pipelines, notebooks, CI/CD et documentation

Rapport
Rédiger, présenter et soutenir

7 semaines

1 livrable / semaine

5 portes GO/NO-GO

1 démo finale

Objectif :
amélioration mesurée, pas promesse gratuite

9. Roadmap tutorat sur 7 semaines

Un fil rouge visible, un livrable chaque semaine

Construire une progression défensive et mesurable

S1 — 1
cadrage + repo + 45 questions

Livrable
scope, règles et questionnaire

GO/NO-GO
périmètre

S2 — 2
baseline notebook

Livrable
notebook baseline + logs initiaux

S3 — 3
contrat JSON + prompts

Livrable
contrat JSON + prompts

GO/NO-GO
baseline

S4 — 4
benchmark complet

Livrable
rapport benchmark + résultats

GO/NO-GO
évaluation

S5 — 5
SFT / LoRA si utile

Livrable
modèle entraîné + config

S6 — 6
GRPO + analyse d'erreurs

Livrable
rapport GRPO + erreurs

GO/NO-GO
GRPO

S7 — 7
démo + soutenance

Livrable
slides + démo + rapport final

GO/NO-GO
défense

Équipe & rôles

Données
Collecter, nettoyer et structurer

Prompts
Concevoir les prompts et contrats d'entrées/sorties

Modèle
Choisir, entraîner et adapter (SFT/LoRA, GRPO)

Évaluation
Définir les métriques, tester et analyser

Intégration
Pipelines, notebooks, CI/CD et documentation

Rapport
Rédiger, présenter et soutenir

7 semaines

1 livrable / semaine

5 portes GO/NO-GO

1 démo finale

Objectif :
amélioration mesurée, pas promesse gratuite

9. Roadmap tutorat sur 7 semaines

Un fil rouge visible, un livrable chaque semaine

Construire une progression défensive et mesurable

S1 — 1
cadrage + repo + 45 questions

Livrable
scope, règles et questionnaire

GO/NO-GO
périmètre

S2 — 2
baseline notebook

Livrable
notebook baseline + logs initiaux

S3 — 3
contrat JSON + prompts

Livrable
contrat JSON + prompts

GO/NO-GO
baseline

S4 — 4
benchmark complet

Livrable
rapport benchmark + résultats

GO/NO-GO
évaluation

S5 — 5
SFT / LoRA si utile

Livrable
modèle entraîné + config

S6 — 6
GRPO + analyse d'erreurs

Livrable
rapport GRPO + erreurs

GO/NO-GO
GRPO

S7 — 7
démo + soutenance

Livrable
slides + démo + rapport final

GO/NO-GO
défense

Équipe & rôles

Données
Collecter, nettoyer et structurer

Prompts
Concevoir les prompts et contrats d'entrées/sorties

Modèle
Choisir, entraîner et adapter (SFT/LoRA, GRPO)

Évaluation
Définir les métriques, tester et analyser

Intégration
Pipelines, notebooks, CI/CD et documentation

Rapport
Rédiger, présenter et soutenir

7 semaines

1 livrable / semaine

5 portes GO/NO-GO

1 démo finale

Objectif :
amélioration mesurée, pas promesse gratuite

9. Roadmap tutorat sur 7 semaines

Un fil rouge visible, un livrable chaque semaine

Construire une progression défensive et mesurable

S1 — 1
cadrage + repo + 45 questions

Livrable
scope, règles et questionnaire

GO/NO-GO
périmètre

S2 — 2
baseline notebook

Livrable
notebook baseline + logs initiaux

S3 — 3
contrat JSON + prompts

Livrable
contrat JSON + prompts

GO/NO-GO
baseline

S4 — 4
benchmark complet

Livrable
rapport benchmark + résultats

GO/NO-GO
évaluation

S5 — 5
SFT / LoRA si utile

Livrable
modèle entraîné + config

S6 — 6
GRPO + analyse d'erreurs

Livrable
rapport GRPO + erreurs

GO/NO-GO
GRPO

S7 — 7
démo + soutenance

Livrable
slides + démo + rapport final

GO/NO-GO
défense

Équipe & rôles

Données
Collecter, nettoyer et structurer

Prompts
Concevoir les prompts et contrats d'entrées/sorties

Modèle
Choisir, entraîner et adapter (SFT/LoRA, GRPO)

Évaluation
Définir les métriques, tester et analyser

Intégration
Pipelines, notebooks, CI/CD et documentation

Rapport
Rédiger, présenter et soutenir

7 semaines

1 livrable / semaine

5 portes GO/NO-GO

1 démo finale

Objectif :
amélioration mesurée, pas promesse gratuite

9. Roadmap tutorat sur 7 semaines

Un fil rouge visible, un livrable chaque semaine

Construire une progression défensive et mesurable

S1 — 1
cadrage + repo + 45 questions

Livrable
scope, règles et questionnaire

GO/NO-GO
périmètre

S2 — 2
baseline notebook

Livrable
notebook baseline + logs initiaux

S3 — 3
contrat JSON + prompts

Livrable
contrat JSON + prompts

GO/NO-GO
baseline

S4 — 4
benchmark complet

Livrable
rapport benchmark + résultats

GO/NO-GO
évaluation

S5 — 5
SFT / LoRA si utile

Livrable
modèle entraîné + config

S6 — 6
GRPO + analyse d'erreurs

Livrable
rapport GRPO + erreurs

GO/NO-GO
GRPO

S7 — 7
démo + soutenance

Livrable
slides + démo + rapport final

GO/NO-GO
défense

Équipe & rôles

Données
Collecter, nettoyer et structurer

Prompts
Concevoir les prompts et contrats d'entrées/sorties

Modèle
Choisir, entraîner et adapter (SFT/LoRA, GRPO)

Évaluation
Définir les métriques, tester et analyser

Intégration
Pipelines, notebooks, CI/CD et documentation

Rapport
Rédiger, présenter et soutenir

7 semaines

1 livrable / semaine

5 portes GO/NO-GO

1 démo finale

Objectif :
amélioration mesurée, pas promesse gratuite